

IACD – Trabalho #1

From Raw Detections to Real Intelligence

Relatório Técnico

Licenciatura em IACD | 2025/2026

António Gomes | Nº 53845

1. Introdução

1.1 Descrição do Problema

O presente trabalho insere-se na unidade curricular de Interação com Modelos de Larga Escala e tem como objetivo construir um pipeline de análise de dados de retalho capaz de transformar eventos brutos de deteção computacional em inteligência acionável para o gestor de loja.

O sistema de visão computacional monitoriza 23 zonas de uma loja e produz, para cada pessoa detetada, três tipos de eventos: entry (entrada numa zona), exit (saída de uma zona) e linger (registro da duração de permanência). O dataset cobre sete dias consecutivos de operação, das 09h00 às 21h00, com aproximadamente 250.000 eventos no total.

O desafio central é que os eventos não têm um identificador de pessoa — múltiplas pessoas estão presentes em simultâneo e os seus eventos estão intercalados no stream por ordem cronológica. O objetivo do pipeline é: (1) reconstruir trajetórias individuais; (2) calcular métricas de comportamento de cliente; (3) sintetizar insights acionáveis em linguagem natural, aplicando estratégias de prompts diferentes; e (4) gerar um briefing semanal para o gestor.

1.2 Dificuldades Encontradas

Stitcher

- Logística de calcular o melhor caminho sem o `person_id`: sem identificador de pessoa, é necessário um algoritmo de data association que associe eventos a trajetórias com base em atributos (género, faixa etária) e restrições temporais e espaciais. A escolha errada de parâmetros resulta em fusão de trajetórias de pessoas distintas.
- Otimização: a implementação ingénua com `iterrows` do `pandas` era demasiado lenta para 250.000 eventos. A solução foi converter os dados para listas de dicionários Python na Fase A (extração de zone visits), reduzindo o tempo de execução em ~20x.
- Completude: garantir que todas as trajetórias começam em `Z_E1` ou `Z_E2` e terminam em `Z_E`, `Z_CK` ou por gap >5 min, sem excecionar casos especiais que comprometessem a generalização para o dataset de validação.
- Cobertura: a heurística H7 (entrada obrigatória em `Z_E`) descarta visits de zonas internas sem trajetória ativa ou adormecida disponível, resultando numa cobertura de apenas 51,7%. A tensão entre rigor das regras de negócio e cobertura de dados é a principal limitação do sistema.
- Viabilidade dos resultados: assegurar que as métricas de qualidade (consistência, completude, estabilidade de atributos) são calculadas de forma honesta e não sobreajustadas ao dataset de treino.

Base de Dados

- Erros nos dados: os atributos demográficos têm ~8% de erro no campo `gender` e ~12% no campo `age_range`, introduzidos pela visão computacional em condições reais. Isto significa que a coerência dos resultados nunca pode ser de 100% — o sistema tem de ser tolerante a erros de sensor sem comprometer a estabilidade das trajetórias.

Insights

- Configuração do LLM: o modelo local `mistral:7b` tem um contexto limitado (~8K tokens), o que obrigou a compactar o `metrics.json` antes de o enviar ao modelo. Adicionalmente, o modelo mostrou tendência a ignorar a categoria anomalia quando o prompt era demasiado longo, o que exigiu múltiplas iterações de engenharia de prompts e, por fim, a

reorganização dos dados por secções nomeadas (SECCAO_4_anomalia) para forçar a cobertura desta categoria.

2. Algoritmo de Stitching

2.1 Descrição Detalhada das Heurísticas

O stitcher opera em duas fases independentes. Na Fase A, dentro de cada zona, agrupa eventos entry/linger/exit em visitas coerentes usando uma fila de entradas pendentes e uma função de score de atributos. Na Fase B, para cada zone visit ordenada cronologicamente, avalia todas as trajetórias ativas e seleciona a de menor $\text{score} = \text{gap_segundos} + \text{penalidade_atributos}$. A complexidade é $O(n \log n)$ para a ordenação e $O(n \times k)$ para o stitching, onde $k < 300$ trajetórias ativas em simultâneo.

As dez heurísticas implementadas são:

- H1 — Consistência temporal: $\text{gap} < 0 \rightarrow$ rejeição hard. Sobreposição temporal entre zonas diferentes é fisicamente impossível.
- H2 — Plausibilidade temporal: $\text{gap} > 5 \text{ min} \rightarrow$ rejeição hard e fim de trajetória. Conforme o enunciado: "transições com gap superior a 5 minutos sem detecção podem indicar fim de trajetória".
- H3 — Consistência de atributos por votação: cada trajetória mantém contadores de gender e age_range. Após 2 observações consistentes, o atributo fica bloqueado — divergências posteriores são rejeição hard. Antes do bloqueio, aplicam-se penalidades de 150s por atributo divergente.
- H4 — Estrutura entry→linger→exit: explorada na Fase A para associar os três tipos de evento dentro de cada zona, usando a fila de entradas pendentes.
- H5 — Adjacência física via Dijkstra: os walk_seconds do zones.json são tempos médios; aceita chegadas até 40% mais rápidas (WALK_MARGIN=0,6). Transições abaixo deste limiar são rejeitadas. Dijkstra é necessário para calcular o tempo entre pares não-adjacentes.
- H6 — Z_CK terminal: ao chegar a Z_CK, a trajetória fecha definitivamente. O layout físico da loja não permite reentradas após o corredor de saída.
- H7 — Entrada obrigatória em Z_E1/Z_E2: visitas que não encaixam em nenhuma trajetória ativa e não são de Z_E são descartadas. Não se inventam caminhos.
- H8 — Limite de dia: uma trajetória não cruza a meia-noite. A loja opera das 09h às 21h — nenhuma visita é inter-dia.
- H9 — Duração máxima de 4 horas: visitas com duração superior são consideradas fusões indevidas de múltiplas pessoas. O p95 do dataset é ~30 min, tornando 4h um limiar conservador mas eficaz.
- H10 — Pool de adormecidas (30 min): trajetórias fechadas por gap ficam disponíveis 30 minutos para reativação, refletindo falhas temporárias de sensor ou passagens por zonas não monitorizadas.

2.2 Justificação de Cada Escolha

H1 e H2 derivam diretamente do enunciado e são inegociáveis. H3 foi preferida à rejeição imediata por atributo divergente porque os dados têm ~8–12% de erro de sensor — rejeitar todas as divergências resultaria em trajetórias demasiado curtas e fragmentação excessiva. O mecanismo de votação com bloqueio tardio é um compromisso entre tolerância a ruído e estabilidade a longo prazo.

H5 usa WALK_MARGIN=0,6 em vez de tratar os walk_seconds como mínimos absolutos, porque estes representam tempos médios observados e não limites físicos. Aceitar chegadas 40% mais

rápidas que a média reflete variabilidade natural (corrida leve, caminho mais direto). H10 usa 30 minutos como limite do pool de adormecidas — tempo suficiente para a maioria das ausências por falha de sensor, mas curto o suficiente para não fundir trajetórias de dias diferentes.

2.3 Métricas de Qualidade Obtidas

Métrica	Valor	Alvo	Observação
Consistência temporal	100,0%	100%	Nenhuma sobreposição detetada
Compleitude (Z_E→Z_E/Z_CK)	99,7%	>50%	Apenas 18 trajetórias incompletas
Início em Z_E	100,0%	100%	Obrigatório por H7
Cobertura (estimada)	51,7%	—	Descarte por H7 em traj. parciais
Estabilidade gender	91,0%	>90%	Erro sensor ~8% — dentro do esperado
Estabilidade age_range	81,3%	>80%	Erro sensor ~12% — dentro do esperado
Gap mediano entre zonas	21s	<120s	Plausível para loja de retalho
Pessoas reconstruídas	6.445	—	7 dias × horário 09h–21h

2.4 Análise de Casos de Falha

Cobertura (51,7%)

A cobertura baixa resulta da conjugação de H2 (gap >5 min fecha trajetória) e H7 (só Z_E cria trajetória). Quando um visit de zona interna aparece após uma pausa longa sem trajetória ativa ou adormecida disponível, é descartado. Os casos mais frequentes são: (a) pessoas que entraram antes das 09h00 cujo evento Z_E não foi registado; (b) eventos Z_E perdidos por falha de sensor; (c) trajetórias adormecidas já expiradas após os 30 minutos de pool.

Coerência dos Resultados

A inconsistência de atributos — gender: 9% de mudanças; age_range: 18,7% — está dentro do esperado dado os erros de sensor declarados (~8% e ~12%). O mecanismo de votação da H3 absorve parte destas divergências, mas não todas: antes do bloqueio (2 observações consistentes), o sistema ainda aceita visits com atributos divergentes mediante penalidade. Trajetórias curtas (1–2 visits) ficam particularmente vulneráveis a fusões indevidas porque o atributo nunca chega a ser bloqueado.

3. Pipeline Analítico

3.1 Métricas Calculadas

O analytics.py calcula cinco secções de métricas a partir do journeys.csv:

- Tráfego: visitantes únicos por dia e por hora (média semanal); distribuição por dia da semana; duração média e p95 de visita; hora de pico; dia mais e menos movimentado.
- Zonas: tráfego por zona (visitantes únicos); dwell time médio por zona; taxa de paragem (visitantes com linger / visitantes totais); top-10 sequências de zonas como bigramas.
- Funil: alcance por zona em percentagem do total de visitantes; taxa de conversão para Z_CK; taxa de abandono; perfil demográfico dos não-compradores (género, faixa etária, zonas visitadas em média).

- Demográfico: distribuição de género por hora do dia; top-5 segmentos (género × faixa etária) por dwell time médio.
- Anomalias: para cada zona e cada hora, calcula média e desvio padrão do tráfego nos primeiros 6 dias; identifica as zonas/horas onde o dia 7 se desvia mais de 2σ da média; devolve top-10 ordenado por magnitude do desvio.

3.2 Decisões sobre o Que Incluir e Excluir (e Porquê)

Incluído

- Dwell time médio: calculado exclusivamente sobre visits com dwell_s > 0 (eventos linger reais). Incluir visits sem linger (dwell=0) produziria uma média artificialmente baixa e não refletiria o tempo real de permanência.
- Bigramas de sequências (zona→zona): em vez de trajetórias completas, que têm variância demasiado elevada para identificar padrões recorrentes. Os bigramas capturam os fluxos mais comuns de forma acionável para o gestor.
- Perfil demográfico dos não-compradores: relevante para o gestor perceber quem abandona a loja sem comprar e desenhar estratégias de retenção dirigidas.

Excluído

- Distribuição de faixa etária por hora (age_by_hour): estrutura demasiado grande para o contexto do modelo (23 horas × N categorias × 7 dias). Substituída pelo top-5 de segmentos por dwell time.
- Dwell time por segmento e por zona (dwell_by_segment_zone): a combinação zona × género × faixa etária produzia centenas de registos, tornando o JSON demasiado grande para o contexto do mistral:7b.
- Baseline completo das anomalias (todos os dias × todas as zonas × todas as horas): foi limitado ao top-10 para reduzir o tamanho do JSON sem perda de informação acionável.

3.3 Formato do metrics.json

O metrics.json tem cinco secções de primeiro nível com as chaves traffic, zones, funnel, demographics e anomalies. O tamanho final é de aproximadamente 8 KB, otimizado para caber no contexto de 8.192 tokens do mistral:7b com margem para o prompt e para a resposta. A renomeação das secções para SECCAO_1_trafego, SECCAO_2_zona, etc. é feita pelo módulo insights.py na função _compact_metrics(), imediatamente antes de enviar os dados ao modelo, para facilitar a associação entre dados e categoria de insight (visualizado no ANEXO - E).

4. Engenharia de Prompts

O módulo insights.py utiliza o modelo local mistral:7b via Ollama (temperature=0, seed=42, num_ctx=8192) para gerar insights acionáveis em português europeu a partir do metrics.json. Foram implementadas e comparadas duas estratégias de prompting.

4.1 Prompts Completos

Estratégia A — Zero-Shot (prompt completo)

És um analista de retalho experiente. Recebes métricas de uma loja calculadas em Python e deves gerar insights acionáveis em português europeu.

REGRAS OBRIGATÓRIAS:

- Cada insight deve conter números concretos dos dados (nunca ser vago).
- A observacao deve citar valores exactos (contagens, percentagens, tempos).
- A recomendacao deve ser uma acção concreta que o gestor pode executar esta semana.
- Responde APENAS com JSON válido, sem texto adicional, sem blocos de código.
- Gera obrigatoriamente pelo menos 1 insight de cada categoria (trafego, zona, funil, ANOMALIA, demografico).

SCHEMA OBRIGATÓRIO:

```
{
  "insights": [
    {
      "id": "INS_001",
      "categoria": "trafego|zona|funil|anomalia|demografico",
      "titulo": "frase curta que resume o insight (max 10 palavras)",
      "observacao": "factos e números concretos dos dados",
      "implicacao": "o que isto significa operacionalmente para a loja",
      "recomendacao": "acção concreta e especifica que o gestor pode tomar",
      "urgencia": "imediata|esta_semana|proximo_mes",
      "confianca": 0.0
    }
  ],
  "resumo_executivo": "3 bullets separados por | com os insights mais importantes"
}
```

DADOS (metrics.json):

{METRICS}

Estratégia B — Few-Shot (prompt completo)

És um analista de retalho experiente. Recebes métricas de uma loja calculadas em Python e deves gerar insights accionáveis em português europeu.

REGRAS OBRIGATÓRIAS:

- Cada insight deve conter números concretos dos dados (nunca ser vago).
- A observacao deve citar valores exactos (contagens, percentagens, tempos).
- A recomendacao deve ser uma acção concreta que o gestor pode executar esta semana.
- Responde APENAS com JSON válido, sem texto adicional, sem blocos de código.
- Gera obrigatoriamente pelo menos 1 insight de cada categoria (trafego, zona, funil, anomalia, demografico).

EXEMPLOS DO QUE NÃO FAZER (mau insight — genérico e vago):

MAU EXEMPLO 1:

```
{
  "titulo": "A zona de frescos teve bastante tráfego.",
  "observacao": "Houve muitos visitantes na zona de frescos.",
  "implicacao": "O tráfego foi elevado.",
  "recomendacao": "Recomenda-se melhorar o atendimento ao cliente."
}
```

Problema: sem números, sem zona específica, recomendação não accionável.

MAU EXEMPLO 2:

```
{
  "titulo": "Houve uma anomalia na loja.",
  "observacao": "O tráfego foi anormal numa zona.",
  "implicacao": "Pode haver um problema.",
  "recomendacao": "Investigar o problema."
}
```

Problema: não identifica zona, hora, nem magnitude do desvio.

EXEMPLOS DO QUE FAZER (bom insight – específico e accionável):

BOM EXEMPLO 1 (par com MAU EXEMPLO 1):

```
{
  "titulo": "Z_S3 com pico 31% acima da média na quinta-feira",
  "observacao": "A zona Z_S3 teve 847 visitantes na quinta-feira, 31% acima da média semanal.",
  "implicacao": "Procura concentrada num dia da semana – risco de rutura de stock e filas.",
  "recomendacao": "Reforçar reposição de produto em Z_S3 às quintas-feiras antes das 10h."
}
```

BOM EXEMPLO 2:

```
{
  "titulo": "Z_C2 saturada às quartas entre 12h-13h com espera de 4.2 min",
  "observacao": "Às quartas entre 12h-13h, o tempo médio de espera em Z_C2 foi 4.2 minutos – abrir uma terceira caixa neste slot reduziria o tempo para menos de 2 minutos com base no volume observado.",
  "implicacao": "Caixa central saturada à hora de almoço às quartas – experiência de cliente degradada.",
  "recomendacao": "Abrir caixa adicional em Z_C2 às quartas entre as 12h e as 13h30."
}
```

BOM EXEMPLO 3 (par com MAU EXEMPLO 2):

```
{
  "titulo": "Z_N4 com 0 visitantes às 16h no domingo – possível obstrução",
  "observacao": "No domingo às 16h, Z_N4 teve 0 visitantes contra uma média de 23 – possível obstrução ou problema de sinalização.",
  "implicacao": "Queda abrupta a zero é fisicamente improvável sem causa externa – evento operacional não registado.",
  "recomendacao": "Verificar registo de ocorrências do domingo às 16h e inspecionar o corredor Z_N4."
}
```

SCHEMA OBRIGATÓRIO:

```
{
  "insights": [
    {
      "id": "INS_001",
      "categoria": "trafego|zona|funil|anomalia|demografico",
      "titulo": "frase curta que resume o insight (max 10 palavras)",
      "observacao": "factos e números concretos dos dados",
      "implicacao": "o que isto significa operacionalmente para a loja",
      "recomendacao": "ação concreta e específica que o gestor pode tomar",
      "urgencia": "imediatesta_semanaproximo_mes",
      "confianca": 0.0
    }
  ],
  "resumo_executivo": "3 bullets separados por | com os insights mais importantes"
}
```

DADOS (metrics.json):

{METRICS}

4.2 Comparação Quantitativa A vs. B

O score combinado é calculado como: $\text{score} = 0,4 \times \text{especificidade} + 0,3 \times \text{menção_zona} + 0,3 \times \text{completude}$.

Métrica	Estratégia A	Estratégia B	Observação
Especificidade (obs. c/ números)	80%	100%	B força valores concretos
Menção de zona (Z_XX)	0%	40%	B referencia zonas específicas
Compleitude de campos	100%	100%	Ambas preenchem o schema
Score combinado	0,620	0,820	B vence em +0,200
Tempo de geração	29,9s	31,1s	Diferença negligenciável
Categorias cobertas	5/5	5/5	Schema pré-preenchido garante cobertura

4.3 Exemplos de Bons e Maus Outputs

Maus insights (Estratégia A — genéricos e vagos)

- "Anomalias de tráfego em determinadas zonas" — não identifica zona nem hora específica.
- "Percentual de visitantes que chegam ao checkout" — não cita percentagem exata nem compara com benchmark.
- "Criar estratégias de marketing personalizadas" — recomendação vaga, não acionável.

Bons insights (Estratégia B — específicos e acionáveis)

- "Z_N2 com pico anormal no dia 16/03/2025: Z_N2 teve 15 visitantes contra média de 9,0 — possível obstrução." — zona, data, valor observado, valor de referência, causa hipotética.
- "Maior percentagem de visitantes sem compra são mulheres: 26,3% das visitantes não fizeram checkout; 50,7% eram mulheres." — números concretos e acionáveis.
- "Sábado com maior tráfego: 981 visitantes, 6% acima da média semanal. Reforçar reposição às sextas antes das 10h." — facto + implicação + ação.

4.4 Iterações Realizadas

1. Prompt genérico sem schema: o modelo produzia texto livre, inutilizável para o pipeline.
2. Adição do schema JSON: o modelo produzia JSON mas ignorava frequentemente a categoria anomalia.
3. Dados estruturados por secção (SECCAO_1_trafego, etc.): ao rotular os dados com a categoria correspondente, o modelo deixou de ignorar anomalias — a alteração mais eficaz.
4. Schema pré-preenchido com 5 slots por categoria: eliminou variações no número de insights produzidos.
5. Exemplos few-shot colocados após os dados: colocar os exemplos no final do prompt (após os dados) em vez de antes aumenta a atenção do modelo, pois o conteúdo mais recente tem maior peso no contexto.

5. Avaliação

5.1 Resultados do Harness no Dataset de Treino

O harness de avaliação (evaluate.py) corre o pipeline completo sobre o dataset de validação e calcula seis métricas automaticamente. Os resultados obtidos sobre o dataset de treino com anomalias injetadas (inject_anomalies.py, seed=42) foram:

Métrica	Valor	Threshold	Estado
Consistência	100,0%	100%	✓ Passou
Cobertura	51,56%	90%	X Não passou
Compleitude	99,71%	50%	✓ Passou
Deteção de anomalias	6,45%	50%	X Não passou
Precisão numérica	85,00%	70%	✓ Passou
Ausência de alucinação	94,44%	70%	✓ Passou
Score global	72,86%	—	4/6 métricas passaram

5.2 Análise de Falhas

Cobertura (51,56%) — Falha

A cobertura baixa resulta diretamente da conjugação de H2 e H7. Quando um visit de zona interna aparece após um gap >5 min sem trajetória ativa ou adormecida disponível, é descartado. Este comportamento é correto do ponto de vista das regras de negócio — não se podem inventar trajetórias — mas penaliza datasets com muitas trajetórias parciais do início/fim do dia.

Deteção de Anomalias (6,45%) — Falha

O harness detetou 31 anomalias estatísticas (desvio $>2\sigma$ no último dia vs. baseline de 6 dias), mas o LLM identificou apenas 2 nos insights. O modelo condensa múltiplas anomalias num único insight de categoria anomalia, ignorando as de menor magnitude. Esta limitação não é do algoritmo de deteção (que segue o critério do enunciado), mas da capacidade do modelo de 7B parâmetros para enumerar múltiplos eventos anómalos dentro do limite de 2.000 tokens de output.

5.3 Limitações Honestas do Sistema

- A cobertura de 51,7% significa que aproximadamente metade dos eventos do dataset não é atribuída a nenhuma trajetória, perdendo-se informação potencialmente relevante.
- A deteção de anomalias pelo LLM (6,45%) é demasiado baixa para ser útil em produção — o gestor receberia no máximo 1-2 anomalias identificadas quando pode haver dezenas.
- O mistral:7b gera consistentemente português do Brasil ("percentual", "gênero", "ótimo") em vez de português europeu, apesar da instrução explícita no prompt.
- O sistema não está otimizado para o dataset de validação do professor — foi desenvolvido com base no dataset de treino e nas regras do enunciado, sem ajuste específico para os dados de avaliação.
- A métrica de cobertura usa uma estimativa ($\text{linger} \times 3 + \text{sem_linger} \times 2$ eventos por visit) e não uma contagem exata, podendo haver algum desvio.

6. Conclusão

6.1 O Que Funcionou

- Consistência temporal de 100% e completude de 99,7% demonstram que as heurísticas de stitching são robustas e corretas para o domínio de loja de retalho.

- A separação Python/LLM provou ser a decisão arquitetural mais importante: a precisão numérica de 85% e a ausência de alucinação de 94,4% mostram que fornecer métricas pré-calculadas ao LLM reduz drasticamente os erros factuais.
- O mecanismo de votação de atributos (H3) absorveu eficazmente os erros de sensor declarados, mantendo estabilidade de gender em 91% e age_range em 81,3%.
- A estratégia B (few-shot) superou consistentemente a A (zero-shot) com +0,200 no score, confirmando o valor de exemplos concretos para modelos locais de capacidade limitada.
- O harness de avaliação end-to-end é genuinamente genérico — não está otimizado para o dataset de treino e deve generalizar bem para o dataset de validação do professor.

6.2 O Que Não Funcionou

- A cobertura de 51,7% ficou muito aquém do esperado. A heurística H7 é conceptualmente correta mas penaliza excessivamente datasets com trajetórias parciais do início/fim do dia.
- A deteção de anomalias pelo LLM (6,45%) é a métrica mais fraca e diretamente limitada pela capacidade do modelo local. Um modelo de 7B parâmetros não consegue enumerar múltiplos eventos anómalos numa única resposta de comprimento limitado.
- A configuração do LLM exigiu significativamente mais iterações do que o esperado, especialmente para garantir cobertura consistente da categoria anomalia na estratégia B.

6.3 O Que Faria de Diferente

6. Implementar o Hungarian Algorithm (algoritmo de Kuhn-Munkres) em vez de stitching greedy para obter uma associação globalmente ótima em vez de localmente ótima — potencialmente melhorando tanto a cobertura como a qualidade das trajetórias.
7. Para a deteção de anomalias, gerar um insight por anomalia detetada com múltiplas chamadas ao LLM, ou usar um modelo maior como o mistral:22b, para aumentar a taxa de deteção além dos 6,45% atuais.
8. Implementar uma segunda passagem do stitcher com heurísticas mais relaxadas para os visits descartados, de modo a recuperar cobertura sem comprometer a consistência das trajetórias principais.
9. Avaliar modelos maiores (llama3.1:70b, mistral:22b) para a tarefa de síntese, reservando o mistral:7b apenas para tarefas de classificação simples onde o contexto é suficiente.

6.4 Experiência Retirada do Projeto

Este projeto demonstrou na prática que os maiores desafios em sistemas de IA aplicados não são os algoritmos em si, mas sim a qualidade e estrutura dos dados de entrada. O algoritmo de stitching foi redesenhado múltiplas vezes não por falhas algorítmicas, mas por características do dataset que só se tornaram evidentes ao analisar os resultados em detalhe — como a prevalência de trajetórias parciais e os erros de sensor nos atributos demográficos.

A engenharia de prompts revelou-se igualmente iterativa e surpreendente: pequenas mudanças na estrutura dos dados enviados ao LLM — como rotular as secções com o nome da categoria — tiveram um impacto desproporcional na qualidade dos outputs. A lição mais importante é que a qualidade do input ao LLM é tão ou mais importante que a escolha do modelo.

Por fim, a decisão de separar computação (Python) de síntese (LLM) provou ser não apenas correta do ponto de vista de engenharia, mas também essencial para a auditabilidade do sistema: a existência do metrics.json como registo imutável das métricas calculadas permitiu verificar em qualquer momento se o LLM estava a alucinar valores — uma prática que deve ser padrão em qualquer sistema de IA em produção.

Anexo A — Prompt Estratégia A (Zero-Shot)

És um analista de retalho experiente. Recebes métricas de uma loja calculadas em Python e deves gerar insights accionáveis em português europeu.

REGRAS OBRIGATÓRIAS:

- Cada insight deve conter números concretos dos dados (nunca ser vago).
- A observacao deve citar valores exactos (contagens, percentagens, tempos).
- A recomendacao deve ser uma acção concreta que o gestor pode executar esta semana.
- Responde APENAS com JSON válido, sem texto adicional, sem blocos de código.
- Gera obrigatoriamente pelo menos 1 insight de cada categoria (trafego, zona, funil, ANOMALIA, demografico).

SCHEMA OBRIGATÓRIO:

```
{
  "insights": [
    {
      "id": "INS_001",
      "categoria": "trafego|zona|funil|anomalia|demografico",
      "titulo": "frase curta que resume o insight (max 10 palavras)",
      "observacao": "factos e números concretos dos dados",
      "implicacao": "o que isto significa operacionalmente para a loja",
      "recomendacao": "acção concreta e especifica que o gestor pode tomar",
      "urgencia": "imediatesta_semana|proximo_mes",
      "confianca": 0.0
    }
  ],
  "resumo_executivo": "3 bullets separados por | com os insights mais importantes"
}
```

DADOS (metrics.json):

```
{METRICS}
```

Anexo B — Resultado Estratégia A

```
{
  "insights": [
    {
      "id": "INS_001",
      "categoria": "trafego",
      "titulo": "Maior tráfego diário na loja",
      "observacao": "O dia com maior tráfego diário é o sábado, com uma média de 920.7 visitantes.",
      "implicacao": "A loja pode ter mais demanda no final da semana, portanto, seria interessante ter mais funcionários disponíveis nesse período.",
      "recomendacao": "Aumentar o número de funcionários no fim de semana para melhor atender a demanda.",
      "urgencia": "esta_semana",
      "confianca": 0.9
    },
    {
      "id": "INS_002",
      "categoria": "zona",
      "titulo": "Zona mais visitada na loja",
      "observacao": "A zona mais visitada é a Z_E1, com 4089 visitantes.",
      "implicacao": "É importante ter atenção especial nesta zona para garantir uma boa experiência de compra.",
      "recomendacao": "Verificar a organização e limpeza da zona Z_E1 para melhor atender a demanda.",
      "urgencia": "esta_semana",
      "confianca": 0.9
    },
    {
      "id": "INS_003",
      "categoria": "funil",
      "titulo": "Maior percentual de abandono de carrinho na loja",
      "observacao": "O percentual de abandono de carrinho é de 26.3%, com uma maior proporção de visitantes femininas.",
      "implicacao": "É importante identificar as razões por trás do abandono de carrinho para melhorar a conversão.",
      "recomendacao": "Realizar um estudo sobre o motivo pelo qual os clientes abandonam o carrinho na loja, especialmente entre as mulheres.",
      "urgencia": "proximo_mes",
      "confianca": 0.8
    },
    {
      "id": "INS_004",
      "categoria": "anomalia",
      "titulo": "Anomalias de tráfego em zonas específicas",
      "observacao": "Foram identificadas 10 anomalias em uma determinada data, com zonas específicas e horários marcados.",
      "implicacao": "É importante investigar as causas dessas anomalias para melhorar a previsão de tráfego futuro.",
      "recomendacao": "Realizar um estudo sobre as anomalias identificadas para entender suas causas e tomar medidas preventivas.",
      "urgencia": "imediata",
      "confianca": 0.9
    },
    {
      "id": "INS_005",
      "categoria": "demografico",
      "titulo": "Distribuição da idade dos clientes na loja",
      "observacao": "A maior proporção de visitantes é composta por adultos, seguida por jovens adultos e idosos.",
    }
  ]
}
```

```

    "implicacao": "É importante ter produtos e promoções adequados para cada segmento demográfico.",
    "recomendacao": "Realizar um estudo sobre a preferência de produtos e promoções dos diferentes segmentos demográficos na loja.",
    "urgencia": "proximo_mes",
    "confianca": 0.8
  }
],
"resumo_executivo": "Maior tráfego diário no sábado, Zona mais visitada é a Z_E1, Maior percentual de abandono de carrinho entre as mulheres, Anomalias de tráfego em zonas específicas e Distribuição da idade dos clientes na loja",
"evaluation": {
  "strategy": "A",
  "n_insights": 5,
  "especificidade": 0.8,
  "mencao_zona": 0.2,
  "completude": 1.0,
  "score": 0.68,
  "tempo_s": 25.9
}
}

```

Anexo C — Prompt Estratégia B (Few-Shot)

És um analista de retalho experiente. Recebes métricas de uma loja calculadas em Python e deves gerar insights accionáveis em português europeu.

REGRAS OBRIGATÓRIAS:

- Cada insight deve conter números concretos dos dados (nunca ser vago).
- A observacao deve citar valores exactos (contagens, percentagens, tempos).
- A recomendacao deve ser uma acção concreta que o gestor pode executar esta semana.
- Responde APENAS com JSON válido, sem texto adicional, sem blocos de código.
- Gera obrigatoriamente pelo menos 1 insight de cada categoria (tráfego, zona, funil, anomalia, demografico).

EXEMPLOS DO QUE NÃO FAZER (mau insight — genérico e vago):

MAU EXEMPLO 1:

```
{
  "titulo": "A zona de frescos teve bastante tráfego.",
  "observacao": "Houve muitos visitantes na zona de frescos.",
  "implicacao": "O tráfego foi elevado.",
  "recomendacao": "Recomenda-se melhorar o atendimento ao cliente."
}
```

Problema: sem números, sem zona específica, recomendação não accionável.

MAU EXEMPLO 2:

```
{
  "titulo": "Houve uma anomalia na loja.",
  "observacao": "O tráfego foi anormal numa zona.",
  "implicacao": "Pode haver um problema.",
  "recomendacao": "Investigar o problema."
}
```

Problema: não identifica zona, hora, nem magnitude do desvio.

EXEMPLOS DO QUE FAZER (bom insight — específico e accionável):

BOM EXEMPLO 1 (par com MAU EXEMPLO 1):

```
{
  "titulo": "Z_S3 com pico 31% acima da média na quinta-feira",
  "observacao": "A zona Z_S3 teve 847 visitantes na quinta-feira, 31% acima da média semanal.",
  "implicacao": "Procura concentrada num dia da semana — risco de rutura de stock e filas.",
  "recomendacao": "Reforçar reposição de produto em Z_S3 às quintas-feiras antes das 10h."
}
```

BOM EXEMPLO 2:

```
{
  "titulo": "Z_C2 saturada às quartas entre 12h-13h com espera de 4.2 min",
  "observacao": "Às quartas entre 12h-13h, o tempo médio de espera em Z_C2 foi 4.2 minutos — abrir uma terceira caixa neste slot reduziria o tempo para menos de 2 minutos com base no volume observado.",
  "implicacao": "Caixa central saturada à hora de almoço às quartas — experiência de cliente degradada.",
  "recomendacao": "Abrir caixa adicional em Z_C2 às quartas entre as 12h e as 13h30."
}
```

BOM EXEMPLO 3 (par com MAU EXEMPLO 2):

```
{
```

```

    "titulo": "Z_N4 com 0 visitantes às 16h no domingo – possível obstrução",
    "observacao": "No domingo às 16h, Z_N4 teve 0 visitantes contra uma média de 23 – possível obstrução ou problema de sinalização.",
    "implicacao": "Queda abrupta a zero é fisicamente improvável sem causa externa – evento operacional não registado.",
    "recomendacao": "Verificar registo de ocorrências do domingo às 16h e inspecionar o corredor Z_N4."
  }

```

SCHEMA OBRIGATÓRIO:

```

{
  "insights": [
    {
      "id": "INS_001",
      "categoria": "trafego|zona|funil|anomalia|demografico",
      "titulo": "frase curta que resume o insight (max 10 palavras)",
      "observacao": "factos e números concretos dos dados",
      "implicacao": "o que isto significa operacionalmente para a loja",
      "recomendacao": "acção concreta e especifica que o gestor pode tomar",
      "urgencia": "imediata|esta_semana|proximo_mes",
      "confianca": 0.0
    }
  ],
  "resumo_executivo": "3 bullets separados por | com os insights mais importantes"
}

```

DADOS (metrics.json):

```
{METRICS}
```

Anexo D — Resultado Estratégia B

```
{
  "insights": [
    {
      "id": "INS_001",
      "categoria": "trafego",
      "titulo": "Sábado é o melhor dia da semana com 32% mais visitantes",
      "observacao": "O total de visitantes no sábado foi 1.249 contra uma média semanal de 920,7 – um aumento de 32%.",
      "implicacao": "Aumento significativo do tráfego aos sábados – planeie reforçar o estoque e atendimento.",
      "recomendacao": "Reforçar reposição de produto às sextas-feiras antes das 10h para garantir suprimentos aos sábados.",
      "urgencia": "esta_semana",
      "confianca": 0.95
    },
    {
      "id": "INS_002",
      "categoria": "zona",
      "titulo": "Z_C2 -> Z_C1 é a sequência mais frequente",
      "observacao": "A sequência de zonas mais frequente foi Z_C2 -> Z_C1 com 3.353 visitantes.",
      "implicacao": "Visitantes frequentemente passam pela zona C2 e seguem para a zona C1 – planeie melhorar o atendimento nesta sequência.",
      "recomendacao": "Alocar mais funcionários na zona C2 às horas de pico para garantir um atendimento rápido para os visitantes que seguem para a zona C1.",
      "urgencia": "esta_semana",
      "confianca": 0.9
    },
    {
      "id": "INS_003",
      "categoria": "anomalia",
      "titulo": "Z_N2 com pico de 15 visitantes às 14h no dia 16/03/2025",
      "observacao": "No dia 16/03/2025, o número de visitantes na zona Z_N2 foi 15 contra uma média de 9.0 – um aumento de 64%.",
      "implicacao": "Pico significativo de visitantes em Z_N2 no dia 16/03/2025 às 14h – planeie reforçar o estoque e atendimento.",
      "recomendacao": "Reforçar reposição de produto na zona N2 no dia 16/03/2025 antes das 10h para garantir suprimentos às 14h.",
      "urgencia": "imediata",
      "confianca": 0.9
    },
    {
      "id": "INS_004",
      "categoria": "demografico",
      "titulo": "Mulheres mais propensas a não checar o caixa",
      "observacao": "50,7% das pessoas que não checaram o caixa eram mulheres.",
      "implicacao": "Mulheres mais propensas a abandonar o carrinho – planeie promoções especiais para incentivar as compras.",
      "recomendacao": "Promover ofertas exclusivas para mulheres no final da semana para incentivar as compras e reduzir o número de abandonos do carrinho.",
      "urgencia": "proximo_mes",
      "confianca": 0.85
    }
  ],
  "resumo_executivo": "Aumento significativo do tráfego aos sábados, sequência de zonas mais frequente, pico de visitantes em Z_N2 no dia 16/03/2025 às 14h e mulheres mais propensas a abandonar o carrinho.",
  "evaluation": {
    "strategy": "B",

```

```
"n_insights": 4,  
"especificidade": 1.0,  
"mencao_zona": 0.5,  
"completude": 1.0,  
"score": 0.85,  
"tempo_s": 23.0  
}  
}
```

Anexo E — metrics.json

```
{
  "generated_at": "2026-05-19 01:29:04",
  "source": "journeys.csv",
  "traffic": {
    "total_visitors": 6445,
    "total_days": 7,
    "avg_visitors_per_day": 920.7,
    "max_visitors_day": {
      "date": "2025-03-15",
      "count": 1125
    },
    "min_visitors_day": {
      "date": "2025-03-11",
      "count": 738
    },
    "peak_hour": 17,
    "peak_hour_avg_visitors": 109.9,
    "best_weekday": "Saturday",
    "worst_weekday": "Tuesday",
    "avg_visit_duration_min": 8.9,
    "p95_visit_duration_min": 30.2,
    "visitors_per_day": {
      "2025-03-10": 857,
      "2025-03-11": 738,
      "2025-03-12": 900,
      "2025-03-13": 946,
      "2025-03-14": 857,
      "2025-03-15": 1125,
      "2025-03-16": 1022
    },
    "avg_visitors_per_hour": {
      "9": 34.4,
      "10": 64.4,
      "11": 92.7,
      "12": 106.6,
      "13": 107.7,
      "14": 86.6,
      "15": 77.7,
      "16": 83.1,
      "17": 109.9,
      "18": 105.0,
      "19": 96.0,
      "20": 60.9,
      "21": 17.1
    }
  },
  "zones": {
    "top_zone": "Z_E1",
    "top_zone_visitors": 4089,
    "top_dwell_zone": "Z_S6",
    "top_dwell_avg_s": 206.5,
    "top_stop_zone": "Z_C1",
    "top_stop_rate": 100.0,
    "zone_traffic": {
      "Z_E1": 4089,
      "Z_E2": 3989,
      "Z_C1": 3961,
      "Z_C2": 3886,
      "Z_C3": 2894,
      "Z_CK": 2158,
      "Z_N3": 713,
      "Z_N5": 677,
      "Z_N2": 641,
      "Z_N1": 620,
      "Z_N6": 546,
      "Z_N8": 417,
      "Z_N10": 390,
      "Z_N4": 384,
      "Z_N9": 384,

```

```

    "Z_N7": 289,
    "Z_S1": 241,
    "Z_S5": 202,
    "Z_S4": 177,
    "Z_S3": 160,
    "Z_S6": 104,
    "Z_S2": 100,
    "Z_S7": 85
  },
  "zone_dwell_avg_s": {
    "Z_C1": 23.9,
    "Z_C2": 23.8,
    "Z_C3": 23.8,
    "Z_CK": 189.1,
    "Z_E1": 13.8,
    "Z_E2": 13.7,
    "Z_N1": 187.0,
    "Z_N10": 187.0,
    "Z_N2": 195.2,
    "Z_N3": 190.3,
    "Z_N4": 192.7,
    "Z_N5": 195.4,
    "Z_N6": 189.6,
    "Z_N7": 187.0,
    "Z_N8": 188.1,
    "Z_N9": 192.8,
    "Z_S1": 193.3,
    "Z_S2": 198.1,
    "Z_S3": 199.1,
    "Z_S4": 194.4,
    "Z_S5": 110.8,
    "Z_S6": 206.5,
    "Z_S7": 190.0
  },
  "zone_stop_rate_pct": {
    "Z_C1": 100.0,
    "Z_C2": 100.0,
    "Z_C3": 100.0,
    "Z_CK": 100.0,
    "Z_E1": 100.0,
    "Z_E2": 100.0,
    "Z_N1": 100.0,
    "Z_N10": 100.0,
    "Z_N2": 99.8,
    "Z_N3": 100.0,
    "Z_N4": 100.0,
    "Z_N5": 100.0,
    "Z_N6": 100.0,
    "Z_N7": 100.0,
    "Z_N8": 100.0,
    "Z_N9": 100.0,
    "Z_S1": 100.0,
    "Z_S2": 100.0,
    "Z_S3": 100.0,
    "Z_S4": 100.0,
    "Z_S5": 100.0,
    "Z_S6": 100.0,
    "Z_S7": 100.0
  },
  "top_10_sequences": [
    {
      "seq": "Z_C2 -> Z_C1",
      "n": 3353
    },
    {
      "seq": "Z_C2 -> Z_C3",
      "n": 3247
    },
    {
      "seq": "Z_C1 -> Z_C2",
      "n": 2924
    }
  ]

```

```

    },
    {
      "seq": "Z_C1 -> Z_CK",
      "n": 1598
    },
    {
      "seq": "Z_E1 -> Z_C1",
      "n": 1471
    },
    {
      "seq": "Z_C3 -> Z_C2",
      "n": 1410
    },
    {
      "seq": "Z_E2 -> Z_C2",
      "n": 1066
    },
    {
      "seq": "Z_E2 -> Z_C1",
      "n": 798
    },
    {
      "seq": "Z_E1 -> Z_C2",
      "n": 696
    },
    {
      "seq": "Z_C1 -> Z_E1",
      "n": 563
    }
  ]
},
"funnel": {
  "total_visitors": 6445,
  "reached_checkout_count": 4752,
  "reached_checkout_pct": 73.7,
  "converted_zck_count": 2158,
  "converted_zck_pct": 33.5,
  "no_checkout_count": 1693,
  "no_checkout_pct": 26.3,
  "zone_reach_pct": {
    "Z_C1": 61.5,
    "Z_C2": 60.3,
    "Z_C3": 44.9,
    "Z_CK": 33.5,
    "Z_E1": 63.4,
    "Z_E2": 61.9,
    "Z_N1": 9.6,
    "Z_N10": 6.1,
    "Z_N2": 9.9,
    "Z_N3": 11.1,
    "Z_N4": 6.0,
    "Z_N5": 10.5,
    "Z_N6": 8.5,
    "Z_N7": 4.5,
    "Z_N8": 6.5,
    "Z_N9": 6.0,
    "Z_S1": 3.7,
    "Z_S2": 1.6,
    "Z_S3": 2.5,
    "Z_S4": 2.7,
    "Z_S5": 3.1,
    "Z_S6": 1.6,
    "Z_S7": 1.3
  },
  "no_checkout_profile": {
    "gender_dist": {
      "F": 0.507,
      "M": 0.493
    },
    "age_dist": {
      "adult": 0.285,

```

```

        "middle_aged": 0.223,
        "young_adult": 0.19,
        "senior": 0.128,
        "teenager": 0.089,
        "child": 0.086
    },
    "avg_zones": 1.3
}
},
"demographics": {
    "gender_overall": {
        "M": 0.503,
        "F": 0.497
    },
    "age_overall": {
        "adult": 0.267,
        "middle_aged": 0.23,
        "young_adult": 0.205,
        "senior": 0.119,
        "teenager": 0.094,
        "child": 0.084
    },
    "top_dwell_segments": [
        {
            "gender": "M",
            "age_range": "middle_aged",
            "avg_dwell_s": 63.0
        },
        {
            "gender": "M",
            "age_range": "senior",
            "avg_dwell_s": 60.4
        },
        {
            "gender": "F",
            "age_range": "middle_aged",
            "avg_dwell_s": 60.0
        },
        {
            "gender": "F",
            "age_range": "senior",
            "avg_dwell_s": 57.1
        },
        {
            "gender": "M",
            "age_range": "adult",
            "avg_dwell_s": 56.0
        }
    ],
    "gender_by_hour": {
        "9": {
            "F": 0.485,
            "M": 0.515
        },
        "10": {
            "F": 0.503,
            "M": 0.497
        },
        "11": {
            "F": 0.513,
            "M": 0.487
        },
        "12": {
            "F": 0.495,
            "M": 0.505
        },
        "13": {
            "F": 0.501,
            "M": 0.499
        },
        "14": {

```

```

        "F": 0.472,
        "M": 0.528
    },
    "15": {
        "F": 0.498,
        "M": 0.502
    },
    "16": {
        "F": 0.503,
        "M": 0.497
    },
    "17": {
        "F": 0.49,
        "M": 0.51
    },
    "18": {
        "F": 0.483,
        "M": 0.517
    },
    "19": {
        "F": 0.494,
        "M": 0.506
    },
    "20": {
        "F": 0.512,
        "M": 0.488
    },
    "21": {
        "F": 0.467,
        "M": 0.533
    }
}
},
"anomalies": {
    "baseline_days": [
        "2025-03-10",
        "2025-03-11",
        "2025-03-12",
        "2025-03-13",
        "2025-03-14",
        "2025-03-15"
    ],
    "anomaly_day": "2025-03-16",
    "total_anomalies": 10,
    "anomalies": [
        {
            "zone_id": "Z_N2",
            "hour_of_day": 14,
            "visitors": 15,
            "mean": 9.0,
            "std": 0.63,
            "sigma": 9.49
        },
        {
            "zone_id": "Z_N3",
            "hour_of_day": 21,
            "visitors": 4,
            "mean": 1.75,
            "std": 0.5,
            "sigma": 4.5
        },
        {
            "zone_id": "Z_N6",
            "hour_of_day": 15,
            "visitors": 11,
            "mean": 5.33,
            "std": 1.37,
            "sigma": 4.15
        },
        {
            "zone_id": "Z_N3",

```

```

    "hour_of_day": 20,
    "visitors": 10,
    "mean": 5.33,
    "std": 1.21,
    "sigma": 3.85
  },
  {
    "zone_id": "Z_N7",
    "hour_of_day": 20,
    "visitors": 5,
    "mean": 2.17,
    "std": 0.75,
    "sigma": 3.76
  },
  {
    "zone_id": "Z_C2",
    "hour_of_day": 21,
    "visitors": 16,
    "mean": 7.5,
    "std": 2.35,
    "sigma": 3.62
  },
  {
    "zone_id": "Z_N3",
    "hour_of_day": 15,
    "visitors": 14,
    "mean": 7.33,
    "std": 1.86,
    "sigma": 3.58
  },
  {
    "zone_id": "Z_N9",
    "hour_of_day": 10,
    "visitors": 7,
    "mean": 4.33,
    "std": 0.82,
    "sigma": 3.27
  },
  {
    "zone_id": "Z_N6",
    "hour_of_day": 20,
    "visitors": 8,
    "mean": 3.33,
    "std": 1.51,
    "sigma": 3.1
  },
  {
    "zone_id": "Z_N3",
    "hour_of_day": 16,
    "visitors": 12,
    "mean": 7.0,
    "std": 1.67,
    "sigma": 2.99
  }
]
}
}

```

Anexo F — Insights.json

```
{
  "insights": [
    {
      "id": "INS_001",
      "categoria": "trafego",
      "titulo": "Sábado é o melhor dia da semana com 32% mais visitantes",
      "observacao": "O total de visitantes no sábado foi 1.249 contra uma média semanal de 920,7 – um aumento de 32%.",
      "implicacao": "Aumento significativo do tráfego aos sábados – planeie reforçar o estoque e atendimento.",
      "recomendacao": "Reforçar reposição de produto às sextas-feiras antes das 10h para garantir suprimentos aos sábados.",
      "urgencia": "esta_semana",
      "confianca": 0.95
    },
    {
      "id": "INS_002",
      "categoria": "zona",
      "titulo": "Z_C2 -> Z_C1 é a sequência mais frequente",
      "observacao": "A sequência de zonas mais frequente foi Z_C2 -> Z_C1 com 3.353 visitantes.",
      "implicacao": "Visitantes frequentemente passam pela zona C2 e seguem para a zona C1 – planeie melhorar o atendimento nesta sequência.",
      "recomendacao": "Alocar mais funcionários na zona C2 às horas de pico para garantir um atendimento rápido para os visitantes que seguem para a zona C1.",
      "urgencia": "esta_semana",
      "confianca": 0.9
    },
    {
      "id": "INS_003",
      "categoria": "anomalia",
      "titulo": "Z_N2 com pico de 15 visitantes às 14h no dia 16/03/2025",
      "observacao": "No dia 16/03/2025, o número de visitantes na zona Z_N2 foi 15 contra uma média de 9.0 – um aumento de 64%.",
      "implicacao": "Pico significativo de visitantes em Z_N2 no dia 16/03/2025 às 14h – planeie reforçar o estoque e atendimento.",
      "recomendacao": "Reforçar reposição de produto na zona N2 no dia 16/03/2025 antes das 10h para garantir suprimentos às 14h.",
      "urgencia": "imediata",
      "confianca": 0.9
    },
    {
      "id": "INS_004",
      "categoria": "demografico",
      "titulo": "Mulheres mais propensas a não checar o caixa",
      "observacao": "50,7% das pessoas que não checaram o caixa eram mulheres.",
      "implicacao": "Mulheres mais propensas a abandonar o carrinho – planeie promoções especiais para incentivar as compras.",
      "recomendacao": "Promover ofertas exclusivas para mulheres no final da semana para incentivar as compras e reduzir o número de abandonos do carrinho.",
      "urgencia": "proximo_mes",
      "confianca": 0.85
    }
  ],
  "resumo_executivo": "Aumento significativo do tráfego aos sábados, sequência de zonas mais frequente, pico de visitantes em Z_N2 no dia 16/03/2025 às 14h e mulheres mais propensas a abandonar o carrinho.",
  "strategy_comparison": {
    "winner": "B",
    "score_delta": 0.17,
    "strategy_A": {
      "strategy": "A",
      "n_insights": 5,
      "especificidade": 0.8,
      "mencao_zona": 0.2,
      "completude": 1.0,
      "score": 0.68,
      "tempo_s": 25.9
    }
  }
},
```

```

"strategy_B": {
  "strategy": "B",
  "n_insights": 4,
  "especificidade": 1.0,
  "mencao_zona": 0.5,
  "completude": 1.0,
  "score": 0.85,
  "tempo_s": 23.0
},
"conclusion": "Estrategia B venceu com score 0.850 vs 0.680."
},
"strategy_A_result": {
  "insights": [
    {
      "id": "INS_001",
      "categoria": "trafego",
      "titulo": "Maior tráfego diário na loja",
      "observacao": "O dia com maior tráfego diário é o sábado, com uma média de 920.7 visitantes.",
      "implicacao": "A loja pode ter mais demanda no final da semana, portanto, seria interessante ter mais funcionários disponíveis nesse período.",
      "recomendacao": "Aumentar o número de funcionários no fim de semana para melhor atender a demanda.",
      "urgencia": "esta_semana",
      "confianca": 0.9
    },
    {
      "id": "INS_002",
      "categoria": "zona",
      "titulo": "Zona mais visitada na loja",
      "observacao": "A zona mais visitada é a Z_E1, com 4089 visitantes.",
      "implicacao": "É importante ter atenção especial nesta zona para garantir uma boa experiência de compra.",
      "recomendacao": "Verificar a organização e limpeza da zona Z_E1 para melhor atender a demanda.",
      "urgencia": "esta_semana",
      "confianca": 0.9
    },
    {
      "id": "INS_003",
      "categoria": "funil",
      "titulo": "Maior percentual de abandono de carrinho na loja",
      "observacao": "O percentual de abandono de carrinho é de 26.3%, com uma maior proporção de visitantes femininas.",
      "implicacao": "É importante identificar as razões por trás do abandono de carrinho para melhorar a conversão.",
      "recomendacao": "Realizar um estudo sobre o motivo pelo qual os clientes abandonam o carrinho na loja, especialmente entre as mulheres.",
      "urgencia": "proximo_mes",
      "confianca": 0.8
    },
    {
      "id": "INS_004",
      "categoria": "anomalia",
      "titulo": "Anomalias de tráfego em zonas específicas",
      "observacao": "Foram identificadas 10 anomalias em uma determinada data, com zonas específicas e horários marcados.",
      "implicacao": "É importante investigar as causas dessas anomalias para melhorar a previsão de tráfego futuro.",
      "recomendacao": "Realizar um estudo sobre as anomalias identificadas para entender suas causas e tomar medidas preventivas.",
      "urgencia": "imediate",
      "confianca": 0.9
    },
    {
      "id": "INS_005",
      "categoria": "demografico",
      "titulo": "Distribuição da idade dos clientes na loja",
      "observacao": "A maior proporção de visitantes é composta por adultos, seguida por jovens adultos e idosos."
    }
  ]
}

```

```

    "implicacao": "É importante ter produtos e promoções adequados para cada segmento demográfico.",
    "recomendacao": "Realizar um estudo sobre a preferência de produtos e promoções dos diferentes segmentos demográficos na loja.",
    "urgencia": "proximo_mes",
    "confianca": 0.8
  }
],
"resumo_executivo": "Maior tráfego diário no sábado, Zona mais visitada é a Z_E1, Maior percentual de abandono de carrinho entre as mulheres, Anomalias de tráfego em zonas específicas e Distribuição da idade dos clientes na loja",
"evaluation": {
  "strategy": "A",
  "n_insights": 5,
  "especificidade": 0.8,
  "mencao_zona": 0.2,
  "completude": 1.0,
  "score": 0.68,
  "tempo_s": 25.9
}
},
"strategy_B_result": {
  "insights": [
    {
      "id": "INS_001",
      "categoria": "trafego",
      "titulo": "Sábado é o melhor dia da semana com 32% mais visitantes",
      "observacao": "O total de visitantes no sábado foi 1.249 contra uma média semanal de 920,7 – um aumento de 32%.",
      "implicacao": "Aumento significativo do tráfego aos sábados – planeie reforçar o estoque e atendimento.",
      "recomendacao": "Reforçar reposição de produto às sextas-feiras antes das 10h para garantir suprimentos aos sábados.",
      "urgencia": "esta_semana",
      "confianca": 0.95
    },
    {
      "id": "INS_002",
      "categoria": "zona",
      "titulo": "Z_C2 -> Z_C1 é a sequência mais frequente",
      "observacao": "A sequência de zonas mais frequente foi Z_C2 -> Z_C1 com 3.353 visitantes.",
      "implicacao": "Visitantes frequentemente passam pela zona C2 e seguem para a zona C1 – planeie melhorar o atendimento nesta sequência.",
      "recomendacao": "Alocar mais funcionários na zona C2 às horas de pico para garantir um atendimento rápido para os visitantes que seguem para a zona C1.",
      "urgencia": "esta_semana",
      "confianca": 0.9
    },
    {
      "id": "INS_003",
      "categoria": "anomalia",
      "titulo": "Z_N2 com pico de 15 visitantes às 14h no dia 16/03/2025",
      "observacao": "No dia 16/03/2025, o número de visitantes na zona Z_N2 foi 15 contra uma média de 9.0 – um aumento de 64%.",
      "implicacao": "Pico significativo de visitantes em Z_N2 no dia 16/03/2025 às 14h – planeie reforçar o estoque e atendimento.",
      "recomendacao": "Reforçar reposição de produto na zona N2 no dia 16/03/2025 antes das 10h para garantir suprimentos às 14h.",
      "urgencia": "imediate",
      "confianca": 0.9
    },
    {
      "id": "INS_004",
      "categoria": "demografico",
      "titulo": "Mulheres mais propensas a não checar o caixa",
      "observacao": "50,7% das pessoas que não checaram o caixa eram mulheres.",
      "implicacao": "Mulheres mais propensas a abandonar o carrinho – planeie promoções especiais para incentivar as compras.",
      "recomendacao": "Promover ofertas exclusivas para mulheres no final da semana para incentivar as compras e reduzir o número de abandonos do carrinho.",
    }
  ]
}

```

```
        "urgencia": "proximo_mes",
        "confianca": 0.85
    }
],
"resumo_executivo": "Aumento significativo do tráfego aos sábados, sequência de zonas
mais frequente, pico de visitantes em Z_N2 no dia 16/03/2025 às 14h e mulheres mais
propensas a abandonar o carrinho.",
"evaluation": {
    "strategy": "B",
    "n_insights": 4,
    "especificidade": 1.0,
    "mencao_zona": 0.5,
    "completude": 1.0,
    "score": 0.85,
    "tempo_s": 23.0
}
}
```